

1. Introduction et Contexte

- **1.1 Le contexte industriel et académique** : présentation rapide de l'entreprise / environnement, c'est quoi la RAG, fonctionnement actuel de la RAG à Cardiff
- **1.2 Problématique de stage** : Pas de système de citation à l'origine, but du stage
- **1.3 plan du rapport.**

2. État de l'art

- **2.1 RL et SFT** : DecompTune, EvidenceRL, TRACE, C2 Cite,
- **2.2 Observabilité et diagnostic** : ContextCite, FACTUM (essayer de tester avant fin du stage), how do llm cite, RCA, cite while you generate
- **2.3 Architectures de RAG** : CIM, hifi RAG, CiteFixe, VeriCite, FinGround, FullCite

3. Collecte et Préparation des Données Publiques

- **3.1 Choix des données**: Description des données publiques
- **3.2 Prétraitement et structuration** : Processing chunks (id, text).

4. Exploration Initiale : Expérimentations et Évaluation sur Données Publiques en comparant aux gold chunks pertinents

- **4.1 Stratégies d'interaction (Prompting)** : *Cite-then-Answer* vs *Answer-then-Cite* (1 passe / 2 passes).
- **4.2 Raisonnement et filtrage** : Raisonnement explicite pour la sélection d'informations.
- **4.3 Évaluation sur les *chunks* pertinents et llm as a judge** :
- **4.4 Analyse des limites** : on peut pas utiliser pertinent chunks pour représenter used chunks, même si la réponse est jugée parfaite

5. Construction du Dataset Annoté pour la génération de citations post hoc

- **5.1 Le Dataset** : Choix des données Cardiff et publiques
- **5.2 Construction des retrieved chunks** : proportion random dans une certaine plage pour les GT pertinent chunk, complétion avec faux positifs selon les scores du retriever

- **5.3 Pipeline de Ground Truth** : Génération de réponses, pré-annotation, correction humaine et validation.
- **5.4 Evaluation de la préannotation**

6. Systèmes d'Attribution *Post-hoc*

- **6.1 Décomposition en faits atomiques** pour le NLI : baseline
- **6.2 Le module SEEK** : Adaptation de l'approche pour faire de l'attribution de citations, variantes de l'approche de base au niveau des embeddings (choix du modèle, calcul de la 1ère composante) et variante de filtrage (*Visual Analysis*, *Maximum Gap*).
- **6.3 Architecture finale** : SEEK + NLI
- **6.4 Proxy d'évaluation alternatif** : Mesure des *log-probs* en *teacher forcing* (contextcite).

7. Génération Inline et Décodage Contraint

- **7.1 Stratégies de génération** : *Prompting* vs *Constrained decoding* (vLLM).
- **7.2 Génération des GT used uniquement via preannotation**
- **7.3 Tentatives d'augmentation du rappel**
- **7.4 Qualité des faits atomiques générés à partir d'une réponse qui introduit les citations** : Application du NLI dessus (faits atomiques générés à partir de la réponse en entier avec citation, de la réponse en entier sans citations, des blocs associés à une ou plus citations)

8. Conclusion et Perspectives

- Conclusion - ouverture